

Regulação da Expressão Gênica: Fundamentos e Perspectivas Bioinformáticas

A regulação da expressão gênica refere-se aos mecanismos que controlam quando, onde e com que intensidade um gene é expresso. Esse controle é exercido em vários níveis – desde fatores de transcrição que ativam ou reprimem genes, até modificações epigenéticas e estruturas tridimensionais do genoma – e é essencial para o desenvolvimento, resposta a estímulos e manutenção da homeostase celular ¹ ². De modo geral, **fatores de transcrição** (proteínas que se ligam ao DNA) formam redes regulatórias direcionadas (gene regulatory networks, GRNs) conectando reguladores e genes-alvo ³ ⁴. Esses TFs competem com nucleossomos pela ligação ao DNA e podem amplificar ou reprimir transcrição ⁵ ⁶. Estudos recentes estimam que cerca de 3% dos genes de *Saccharomyces cerevisiae* e mais de 6% dos genes humanos codificam TFs ou cofatores, ressaltando sua importância quantitativa ⁵.

Além dos TFs, **elementos cis-regulatórios** – como promotores e enhancers – definem a atividade transcricional. Tradicionalmente pensava-se que promotores e enhancers tinham funções exclusivas, mas evidências indicam que um mesmo elemento acessível ao DNA pode atuar concomitantemente como promotor e como enhançador ⁷. Andersson e Sandelin (2020), por exemplo, propõem que os elementos regulatórios devam ser definidos pela presença de DNA acessível associado à capacidade de iniciar transcrição e/ou de potencializar a transcrição em outras regiões ⁷. Na prática, enhancers podem interagir fisicamente com promotores a grandes distâncias genômicas, modulando a expressão dos genes-alvo ² ⁸. Tais interações de longo alcance são críticas: embora o genoma se organize em regiões ativas (compartimentos A) e inativas (compartimentos B), proteínas estruturais como CTCF e cohesina formam domínios de associação topológica (TADs) e loops que facilitam ou restringem contatos promotor–enhancer ⁹ ². Curiosamente, estudos experimentais revelaram que a remoção aguda de CTCF, cohesina ou WAPL perturba a estrutura tridimensional (los TADs e loops), mas mantém em grande parte intactas as interações enhancer–promotor e os níveis de transcrição de muitos genes ⁹ ¹⁰. Isso sugere que os contatos de curto prazo não dependem criticamente desses fatores estruturais, embora a cohesina melhore a busca dos TFs por seus alvos no genoma ⁸.

Em níveis posteriores, a **regulação epigenética e pós-transcricional** amplia o controle sobre a expressão gênica. Modificações de histonas e metilação do DNA modulam a acessibilidade cromatínica e a estabilidade dos loci genômicos. Smith et al. (2025) destacam que a metilação de DNA, uma modificação antiga evolutivamente, compõe “códigos epigenéticos” que interagem com outras camadas regulatórias (como histonas e remodeladores) para sustentar diferentes funções genômicas ¹¹. Por sua vez, RNAs não codificantes exercem papel direto na regulação: *lncRNAs* (RNAs longos não codificantes) são amplamente expressos e podem modular a função da cromatina, organizar compartimentos nucleares sem membrana, influenciar estabilidade e tradução de mRNAs, além de interferir em vias de sinalização celular ¹². Essas ações têm impacto final na expressão gênica em contextos biológicos variados. Em resumo, mecanismos como feedback negativo e positivo, interações metabólicas e regulação por RNAs formam uma teia complexa que ajusta precisamente quais genes são ativados ou silenciados ¹³ ¹².

A compreensão global desses mecanismos tem sido favorecida pela integração de abordagens experimentais e computacionais. Graças a técnicas de *sequenciamento de alto rendimento* (RNA-seq, ChIP-seq, ATAC-seq, Hi-C etc.), podemos quantificar expressão gênica e estados cromatínicos em larga

escala. No entanto, os dados brutos precisam ser interpretados por algoritmos poderosos. Por exemplo, o estudo de Gibbs et al. (2022) apresenta o **Inferelator 3.0**, um pipeline de bioinformática que infere redes de regulação gênica a partir de dados de expressão gênica unicelular, usando regressão regularizada com informação prévia ¹⁴. Esse e outros métodos devem resolver um problema desafiador: múltiplas redes plausíveis podem explicar os mesmos dados experimentais ¹⁵. Redes de expressão gênica (GRNs) são geralmente representadas como grafos direcionados e sua inferência requer dados dinâmicos e escaláveis; técnicas emergentes como *single-cell RNA-seq* e experimentos de perturbação em larga escala ajudam a contornar a escassez de “padrões-ouro” para validar redes ¹⁶ ¹⁷.

Nos últimos anos, avanços em **aprendizado de máquina** têm permitido modelar a regulação gênica de maneiras inéditas. Fu et al. (2025) introduziram o **GET (General Expression Transformer)**, um modelo de linguagem inspirado treinado em dados epigenômicos e de acessibilidade cromatínica para prever padrões transcricionais em 54 tipos celulares humanos distintos ¹⁸ ¹⁹. O GET usa atenção hierárquica para capturar interações em diferentes escalas genômicas e prevê com precisão níveis de expressão, além de explicar a “gramática” regulatória aprendida pelo modelo. Da mesma forma, Rafi et al. (2024) organizaram um *desafio DREAM* usando milhões de sequências de promotores aleatórios (em levedura) e níveis de expressão medidos experimentalmente. Modelos de rede neural profunda (CNNs, RNNs, transformers) treinados nesse desafio alcançaram desempenho de estado da arte, superando benchmarks anteriores em levedura, *Drosophila* e dados humanos ⁶ ²⁰. Essas abordagens de aprendizado profundo tornam possível prever expressões gênicas diretamente da sequência de DNA, aproximando-nos de uma decodificação quantitativa do código cis-regulatório. Contudo, a análise crítica mostra que a arquitetura e a estratégia de treinamento impactam fortemente os resultados: Rafi et al. dividiram os modelos vencedores em blocos modulares (estrutura “Prix Fixe”) para otimizar seu desempenho e demonstraram que conjuntos de dados padrão (“gold-standard”) podem impulsionar progressos rápidos na área ⁶.

Outra dimensão emergente é a **inferência de redes regulatórias a partir de dados únicos e multiômicos**. Métodos modernos aproveitam dados emparelhados de expressão gênica e acessibilidade em célula única. Por exemplo, Li et al. (2022) criaram o **DeepTFni**, que usa redes neurais gráficas para inferir interações entre TFs com base em *scATAC-seq* ²¹. Esse método identificou TFs centrais em desenvolvimento tecidual e indica alterações na rede regulatória associadas à leucemia. Mais recentemente, Yuan e Duren (2024) descreveram o **LINGER**, que integra grandes bancos de dados de expressão (bulk) e motivos de TF como regularizadores manifo; com isso, LINGER obteve aumento de 4 a 7 vezes na acurácia de inferência de GRNs em dados multiômicos de célula única, superando métodos anteriores ⁴. Uma revisão de Kim et al. (2023) discute o surgimento dessas técnicas: eles destacam como métodos estatísticos avançados e dados multiômicos combinados estão reconstruindo GRNs mais completos e precisos ²². Além disso, Senapati et al. (2025) propuseram um quadro computacional que conecta mapas de contato 3D (Hi-C) à expressão gênica usando simulações de polímeros. Esse modelo reproduz quantitativamente mudanças de expressão ao perturbar barreiras de TAD (p. ex., entre *sox9* e *kcnj2*), revelando como reorganizações espaciais podem ativar enhancers e inflar a expressão de genes específicos ²³.

Esses estudos exemplificam a transição convergente entre regulação gênica e bioinformática. Enquanto os artigos de revisão destacam a complexidade dos mecanismos regulatórios (metabolismo→regulação gênica ¹³, epigenética ¹¹, RNAs não codificantes ¹²), os avanços técnicos focam na interpretação computacional de dados – seja mapeando elementos regulatórios à escala genômica (Gasperini et al., 2020), seja desenvolvendo modelos preditivos baseados em aprendizado de máquina (Fu et al., 2025; Rafi et al., 2024) e abordagens de rede (Li et al., 2022; Yuan & Duren, 2024; Chevalley et al., 2025). A discussão comparativa destaca que métodos **baseados em física** (Senapati et al., 2025) oferecem explicações mecanicistas a partir da estrutura, enquanto **modelos estatísticos e de ML** capturam

padrões complexos em grandes conjuntos de dados. A combinação dessas perspectivas está enriquecendo nosso entendimento: por exemplo, benchmarks como o **CausalBench** (Chevalley et al., 2025) avaliam algoritmos de inferência contra dados reais perturbados, incentivando a integração de conhecimento biológico em frameworks algorítmicos. Em síntese, há um movimento claro rumo à criação de modelos integrativos que reconcilie dados genômicos multi-ômicos com fundamentos moleculares (do metabolismo até a 3D genomics), sempre buscando rigor técnico e relevância biológica.

Perguntas finais:

- *Tema teórico subjacente:* A regulação da expressão gênica, isto é, os mecanismos e redes moleculares que controlam os níveis de transcrição e tradução de genes em contextos celulares diversos.

- *Principais técnicas utilizadas:* Nas pesquisas consideradas destacam-se métodos de alto fluxo – sequenciamento de RNA (RNA-seq, scRNA-seq), acessibilidade cromatínica (ATAC-seq), interação cromossômica (Hi-C) – combinados com algoritmos de inferência de redes regulatórias (regressão regularizada, mutual info, modelagem física) e aprendizado de máquina (redes neurais convolucionais, recorrentes, transformadores, redes neurais gráficas) para modelar dados genômicos e prever expressão gênica ¹⁴ ⁶.

- *Contribuição geral à ciência:* Os artigos revisados avançam o conhecimento científico ao elucidar novas regras e modelos de regulação gênica (p.ex., integração entre metabolismo e transcrição ¹³, papel de condensados transcrpcionais na decodificação de sinais ²⁴) e ao fornecer ferramentas analíticas poderosas. Em particular, ampliaram-se estratégias computacionais para reconstruir redes regulatórias completas e dinâmicas, facilitando a interpretação de variantes genéticas ligadas a doenças. Coletivamente, esses estudos criam uma base mais robusta para conectar variações no genoma com fenótipos celulares, reforçando o caráter multidisciplinar (molecular e computacional) da regulação gênica.

Referências (seleção com DOI):

- ANDERSSON, R.; SANDELIN, A. *Determinants of enhancer and promoter activities of regulatory elements*. Nat. Rev. Genet., v.21, p.71–87, 2020. DOI: 10.1038/s41576-019-0173-8.
- CHEVALLEY, V. et al. *A large-scale benchmark for network inference from single-cell perturbation data*. Commun. Biol., v.8, art.77, 2025. DOI: 10.1038/s42003-025-07764-y.
- FU, X. et al. *A foundation model of transcription across human cell types*. Nature, v.631, p.79–89, 2025. DOI: 10.1038/s41586-024-08391-z.
- GASPERINI, M.; TOME, J.; SHENDURE, J. *Towards a comprehensive catalogue of validated and target-linked human enhancers*. Nat. Rev. Genet., v.21, p.292–310, 2020. DOI: 10.1038/s41576-019-0209-0.
- GIBBS, C. S. et al. *High-performance single-cell gene regulatory network inference at scale: the Inferelator 3.0*. Bioinformatics, v.38, n.9, p.2519–2521, 2022. DOI: 10.1093/bioinformatics/btac117.
- HORNISCH, M.; PIAZZA, I. *Regulation of gene expression through protein-metabolite interactions*. npj Metab. Health Dis., v.3, art.7, 2025. DOI: 10.1038/s44324-024-00047-w.
- HSIEH, T.-H. S. et al. *Enhancer-promoter interactions and transcription are largely maintained upon acute loss of CTCF, cohesin, WAPL or YY1*. Nat. Genet., v.54, p.1919–1932, 2022. DOI: 10.1038/s41588-022-01223-8.
- KIM, D. et al. *Gene regulatory network reconstruction: harnessing the power of single-cell multi-omic data*. npj Syst. Biol. Appl., v.9, art.51, 2023. DOI: 10.1038/s41540-023-00312-6.
- LI, H. et al. *Inferring transcription factor regulatory networks from single-cell ATAC-seq data based on graph neural networks*. Nat. Mach. Intell., v.4, p.389–400, 2022. DOI: 10.1038/s42256-022-00469-5.
- MEYER, K.; HUANG, B.; WEINER, O. D. *Emerging roles of transcriptional condensates as temporal signal integrators*. Nat. Rev. Genet., v.26, p.559–570, 2025. DOI: 10.1038/s41576-025-00837-y.
- RAFI, A. M. et al. *A community effort to optimize sequence-based deep learning models of gene regulation*. Nat. Biotechnol., 2024. DOI: 10.1038/s41587-024-02414-w.
- SENAPATI, S. et al. *Predicting gene expression changes from chromatin structure modification*. npj Syst. Biol.

Appl., v.11, art.34, 2025. DOI: 10.1038/s41540-025-00510-4.
 SMITH, Z. D.; HETZEL, S.; MEISSNER, A. *DNA methylation in mammalian development and disease*. Nat. Rev. Genet., v.26, p.7–30, 2025. DOI: 10.1038/s41576-024-00760-8.
 STATELLO, L. et al. *Gene regulation by long non-coding RNAs and its biological functions*. Nat. Rev. Mol. Cell Biol., v.22, p.96–118, 2021. DOI: 10.1038/s41580-020-00315-9.
 YUAN, Q.; DUREN, Z. *Inferring gene regulatory networks from single-cell multiome data using atlas-scale external data*. Nat. Biotechnol., v.43, p.247–257, 2025. DOI: 10.1038/s41587-024-02182-7.

1 3 5 14 15 16 17 High-performance single-cell gene regulatory network inference at scale: the Inferelator 3.0 - PMC

<https://pmc.ncbi.nlm.nih.gov/articles/PMC9048651/>

2 Long-range enhancer–promoter contacts in gene expression control | Nature Reviews Genetics

https://www.nature.com/articles/s41576-019-0128-0?error=cookies_not_supported&code=7710b4ca-1ff9-4355-a7c2-77b3d1492497

4 Inferring gene regulatory networks from single-cell multiome data using atlas-scale external data | Nature Biotechnology

https://www.nature.com/articles/s41587-024-02182-7?error=cookies_not_supported&code=2642bb63-565f-4815-a280-9888740ea831

6 20 A community effort to optimize sequence-based deep learning models of gene regulation | Nature Biotechnology

https://www.nature.com/articles/s41587-024-02414-w?error=cookies_not_supported&code=dbfd4be0-37a0-4796-9295-45f294db0bf7

7 Determinants of enhancer and promoter activities of regulatory elements | Nature Reviews Genetics

https://www.nature.com/articles/s41576-019-0173-8?error=cookies_not_supported&code=c9454113-629f-43df-a599-1a3108041d4e

8 9 10 Enhancer–promoter interactions and transcription are largely maintained upon acute loss of CTCF, cohesin, WAPL or YY1 | Nature Genetics

https://www.nature.com/articles/s41588-022-01223-8?error=cookies_not_supported&code=2568d7ad-be1c-4ac8-8359-7961e7a0d649

11 DNA methylation in mammalian development and disease | Nature Reviews Genetics

https://www.nature.com/articles/s41576-024-00760-8?error=cookies_not_supported&code=cb9ea48a-9230-4ed4-b646-f203905ba1ef

12 Gene regulation by long non-coding RNAs and its biological functions | Nature Reviews Molecular Cell Biology

https://www.nature.com/articles/s41580-020-00315-9?error=cookies_not_supported&code=33c63401-956f-4bde-bb32-1f596bdec793

13 Regulation of gene expression through protein-metabolite interactions | npj Metabolic Health and Disease

https://www.nature.com/articles/s44324-024-00047-w?error=cookies_not_supported&code=e4524c19-b845-47ff-928b-7d7c81f39a22

18 19 A foundation model of transcription across human cell types | Nature

https://www.nature.com/articles/s41586-024-08391-z?error=cookies_not_supported&code=25ba3c50-89a9-42b2-b6f9-9403106fd2e9

21 Inferring transcription factor regulatory networks from single-cell ATAC-seq data based on graph neural networks | Nature Machine Intelligence

https://www.nature.com/articles/s42256-022-00469-5?error=cookies_not_supported&code=16611f0f-5f5e-4e29-8082-842c4ec56f5e

22 Gene regulatory network reconstruction: harnessing the power of single-cell multi-omic data | npj Systems Biology and Applications

https://www.nature.com/articles/s41540-023-00312-6?error=cookies_not_supported&code=e2caf6bd-eab3-4b68-9927-b1e5e46928d2

23 Predicting gene expression changes from chromatin structure modification | npj Systems Biology and Applications

https://www.nature.com/articles/s41540-025-00510-4?error=cookies_not_supported&code=cd5cefce-2a8c-4139-a330-fa63a358bc6f

24 Emerging roles of transcriptional condensates as temporal signal integrators | Nature Reviews Genetics

https://www.nature.com/articles/s41576-025-00837-y?error=cookies_not_supported&code=ba159a3f-695c-4519-8995-dd3cc43fb223